

Coding agentique : comparer 7 stacks

Prix, performance, souveraineté, conformité, faisabilité. Tarifs vérifiés sur sources primaires (02/09/2026).

	Claude Code Opus 5 AWS Bedrock	Claude Code Fable 5 AWS Bedrock	Claude Code Sonnet 5 AWS Bedrock	OpenCode DeepSeek V4 Flash preview Albert (DINUM)	OpenCode DeepSeek V4 Flash 0731 Scaleway	OpenCode GLM 5.2 Scaleway	OpenCode Kimi K3 OpenRouter
 Prix / 1M tokens (in / out)	 5 \$ / 25 \$ + siège ≈20 €/m	 10 \$ / 50 \$ + siège ≈20 €/m	 2 \$ / 10 \$ + siège ≈20 €/m	 Gratuit quotas · État	 0,40 € / 0,80 €	 1,80 € / 5,50 €	 2,55 \$ / 12,75 \$ cache —60/80 %
 Performance DeepSWE v1.1 · modèle seul	 74,0 % (±4) TB 89,1* · SV 96 ^v /97*	 70,0 % (±4) TB 83,8 · SV 95,0 ^v	 54 % (±4) TB 80,4 ^v /74,6 · SV 85,2	 7,3 %^v TB 61,8 ^v · SV 73,7 ^v	 53 % · 54,4^v TB 82,7 ^v · SV n.p.	 44,0 % TB 81,0 ^v · SV n.p.	 ≈69 % TB 88,3 ^v · SV 93,4*
 Souveraineté au sens CNIL	 Cloud US CLOUD Act (CNIL)	 Cloud US CLOUD Act (CNIL)	 Cloud US CLOUD Act (CNIL)	 État FR SecNumCloud	 Cloud FR hébergé UE	 Cloud FR hébergé UE	 Éditeur CN + routeur US
 Conformité RGPD / données	 Bonne UE · DPA AWS	 Bonne UE · DPA AWS	 Bonne UE · DPA AWS	 Bonne cadre État	 Bonne RGPD · cloud FR	 Bonne RGPD · cloud FR	 Insuffisante sans garanties UE
 Faisabilité poste interne	 Bedrock (IAM) data sharing	 Bedrock (IAM) data sharing	 Bedrock (IAM) data sharing	 OpenAI-compat. agents État	 clé Scaleway OpenAI-compat.	 clé Scaleway OpenAI-compat.	 clé OpenRouter capacité limitée

Externes, internes : qui paie quoi ?

Le déploiement interne change l'équation économique de l'IA agentique.



Prestataires externes

Abonnement Claude : un forfait mensuel

- Consommation incluse dans le forfait : coût prévisible et plafonné
- Rien à changer : l'outillage actuel reste valable



Agents internes

≈ 20 € / siège / mois + **chaque token au prix du modèle**

- Sièges Claude Enterprise via Bedrock
- Coût à l'usage : l'agentique consomme beaucoup
- Non souverain au sens CNIL (CLOUD Act) · RGPD ok



Conséquence : pour les internes et la CI/CD, le coût au token devient le paramètre clé. C'est l'objet du bench : identifier la stack au meilleur rapport performance / prix / souveraineté.

Repères / 1M tokens (entrée / sortie) : Fable 5 : 10 \$ / 50 \$ · Opus 5 : 5 \$ / 25 \$ · Kimi K3 : 2,55 \$ / 12,75 \$ · Sonnet 5 : 2 \$ / 10 \$ · GLM 5.2 (Scaleway) : 1,80 € / 5,50 € · DeepSeek V4 Flash 0731 (Scaleway) : 0,40 € / 0,80 € · Albert : gratuit, quotas.

Deux cas d'usage, deux logiques de coût

Sur poste : abonnement (siège) ou clé. En CI/CD : paiement au token pour tous.



Code agentique sur poste

- **Claude Code** : siège 20–125 \$/dev/mois
- **OpenCode + Scaleway** : clé, paiement au token (€)
- **OpenCode + OpenRouter** : clé, paiement au token
- **OpenCode + Albert** : clé agent État, gratuit



Bots sur CI/CD

- **Au token pour tous** : pas de siège, clé API
- **Tarifs / 1M en sortie** : de 0,80 € (DS · Scaleway) à 50 \$ (Fable 5)
- **Albert** : gratuit mais quotas 10–50 req/min

Recommandation selon la priorité



Performance

Claude Code · Opus 5

DeepSWE 74 % · TB 89,1 % *. *Non souverain (CLOUD Act).*



Souveraineté & coût

Albert · DeepSeek Flash

Gratuit, SecNumCloud, ≈79 %. *Réservé agents État.*



Rapport perf / prix

DS V4 Flash 0731 · Scaleway

DeepSWE 53 % pour 0,40 / 0,80 € · souverain.
Observabilité à valider.

À noter : OpenCode + Albert documenté par la DINUM (guides.ia.numerique.gouv.fr) · catalogue Albert à confirmer via `/v1/models` · Scaleway = observabilité à valider · Kimi K3 = capacité OpenRouter limitée · modèles Anthropic sur Bedrock = data sharing à activer + rétention 30 j · tarifs OpenRouter = catalogue (caching –60/80 %).