

Coding agentique : comparer 4 stacks

Prix, performance, souveraineté, faisabilité. Tarifs vérifiés sur sources primaires (10/07/2026).

	Claude Code Opus 4.8	OpenCode Albert · DeepSeek V4 Flash	OpenCode GLM 5.2 · OpenRouter	OpenCode DeepSeek V4 Pro · OR
 Prix / 1M tokens	 5 \$ / 25 \$ + siège 20–125 \$/m	 Gratuit quotas, agents État	 ≈1,40 \$ / 4,40 \$	 0,44 \$ / 0,87 \$ tarif preview *
 Performance SWE-bench Verified	 88,6 %	 ≈79 % * via DeepSeek V4 Flash	 ≈78 % * Term-Bench 81–83 %	 80,6 %
 Souveraineté éditeur / hébergement	 Éditeur US CLOUD Act	 État FR SecNumCloud	 Éditeur CN + routeur US	 Éditeur CN + routeur US
 Faisabilité poste interne	 Mac/Linux/Win natif outil mûr, admin. ent.	 OpenAI-compat. agents État · quotas CI	 clé OpenRouter Mac/Linux/Win (WSL)	 clé OpenRouter Mac/Linux/Win (WSL)

●●●●● favorable ●●● moyen ● défavorable * DeepSeek V4 : tarif preview (doublement « peak » mi-07/2026) ; GLM et Albert : perf estimée, catalogue Albert à confirmer.

Externes, internes : qui paie quoi ?

Le déploiement interne change l'équation économique de l'IA agentique.



Prestataires externes

Abonnement Claude : un forfait mensuel

- Consommation incluse dans le forfait : coût prévisible et plafonné
- Rien à changer : l'outillage actuel reste valable



Agents internes

≈ 20 € / siège / mois + **chaque token au prix du modèle**

- Sièges Claude Enterprise via Bedrock : la consommation s'ajoute au siège
- Le coût suit l'usage, et l'agentique consomme beaucoup de tokens



Conséquence : pour les internes et la CI/CD, le coût au token devient le paramètre clé. C'est l'objet du bench : identifier la stack au meilleur rapport performance / prix / souveraineté.

Repères / 1M tokens (entrée / sortie) : Opus 4.8 : 5 \$ / 25 \$ · GLM 5.2 : 1,40 \$ / 4,40 \$ · DeepSeek V4 Pro : 0,44 \$ / 0,87 \$ · Albert (DeepSeek V4 Flash) : gratuit, quotas.

Deux cas d'usage, deux logiques de coût

Sur poste : abonnement (siège) ou clé. En CI/CD : paiement au token pour tous.



Code agentique sur poste

- **Claude Code** : siège 20–125 \$/dev/mois
- **OpenCode + OpenRouter** : clé, paiement au token
- **OpenCode + Albert** : DeepSeek V4 Flash · clé agent État, gratuit



Bots sur CI/CD

- **Au token pour tous** : pas de siège, clé API
- **Tarifs / 1M** : Claude 5/25 · DeepSeek 0,44/0,87 · GLM 1,40/4,40
- **Albert** : gratuit mais quotas 10–50 req/min

Recommandation selon la priorité



Performance & maturité

Claude Code / Opus 4.8

88,6 % SWE-bench, outil mûr. *Coûteux, éditeur US.*



Souveraineté & coût

Albert · DeepSeek V4 Flash

Gratuit, SecNumCloud, ≈79 %. *Réservé agents État.*



Rapport perf / prix

DeepSeek V4 Pro / OR

80,6 % pour ~0,9 \$ / 1M. *Éditeur CN, routeur US, preview.*

À valider : catalogue Albert à confirmer via /v1/models · DeepSeek V4 = tarif preview · tarifs OpenRouter = catalogue (caching –60/80 %) · tokenizer Opus 4.8 ≈ +30 % de tokens.