

Coding agentique : comparer 7 stacks

Prix, performance, souveraineté, conformité, faisabilité. Tarifs vérifiés sur sources primaires (23/07/2026).

	Claude Code Opus 4.8 Anthropic	Claude Code Fable 5 AWS Bedrock	Vibe Medium 3.5 Mistral	OpenCode DeepSeek V4 Flash Albert (DINUM)	OpenCode DeepSeek V4 Pro OpenRouter	OpenCode GLM 5.2 OpenRouter	OpenCode Kimi K3 OpenRouter
 Prix / 1M tokens	●●●●● 5 \$ / 25 \$ + siège 20-125 \$/m	●●●●● 10 \$ / 50 \$ + siège ≈20 €/m	●●●●● 1,50 \$ / 7,50 \$ plans dès 14,99 \$/m	●●●●● Gratuit quotas, agents État	●●●●● 0,44 \$ / 0,87 \$ tarif preview *	●●●●● 1,40 \$ / 4,40 \$	●●●●● 3 \$ / 15 \$ cache —60/80 %
 Performance SWE-bench Verified	●●●●● 88,6 %	●●●●● 95,0 % tête du bench	●●●●● 77,6 %	●●●●● ≈79 % * estimée	●●●●● 80,6 %	●●●●● ≈78 % * estimée	●●●●● 93,4 % * annoncé éditeur
 Souveraineté au sens CNIL	●●●●● Éditeur US CLOUD Act	●●●●● Cloud US CLOUD Act (CNIL)	●●●●● Éditeur FR SecNumCloud en opt.	●●●●● État FR SecNumCloud	●●●●● Éditeur CN + routeur US	●●●●● Éditeur CN + routeur US	●●●●● Éditeur CN + routeur US
 Conformité RGPD / données	●●●●● Partielle transfert hors UE	●●●●● Bonne région UE · DPA AWS	●●●●● Bonne RGPD · éditeur FR	●●●●● Bonne cadre État (DINUM)	●●●●● Insuffisante sans garanties UE	●●●●● Insuffisante sans garanties UE	●●●●● Insuffisante sans garanties UE
 Faisabilité poste interne	●●●●● Multi-OS natif outil mûr, admin ent.	●●●●● Bedrock (IAM) data sharing requis	●●●●● CLI + VS Code clé Mistral ou plan	●●●●● OpenAI-compat. agents État · quotas	●●●●● clé OpenRouter Mac/Linux/Win (WSL)	●●●●● clé OpenRouter Mac/Linux/Win (WSL)	●●●●● clé OpenRouter capacité limitée

●●●●● favorable ●●●●● moyen ●●●●● défavorable * DeepSeek V4 : tarif preview ; GLM et Albert : perf estimée ; Kimi K3 : score annoncé par l'éditeur.

Externes, internes : qui paie quoi ?

Le déploiement interne change l'équation économique de l'IA agentique.



Prestataires externes

Abonnement Claude : un forfait mensuel

- Consommation incluse dans le forfait : coût prévisible et plafonné
- Rien à changer : l'outillage actuel reste valable



Agents internes

≈ 20 € / siège / mois + **chaque token au prix du modèle**

- Sièges Claude Enterprise via Bedrock
- Coût à l'usage : l'agentique consomme beaucoup
- Non souverain au sens CNIL (CLOUD Act) · RGPD ok



Conséquence : pour les internes et la CI/CD, le coût au token devient le paramètre clé. C'est l'objet du bench : identifier la stack au meilleur rapport performance / prix / souveraineté.

Repères / 1M tokens (entrée / sortie) : Fable 5 : 10 \$ / 50 \$ · Opus 4.8 : 5 \$ / 25 \$ · Kimi K3 : 3 \$ / 15 \$ · Mistral Medium 3.5 : 1,50 \$ / 7,50 \$ · GLM 5.2 : 1,40 \$ / 4,40 \$ · DeepSeek V4 Pro : 0,44 \$ / 0,87 \$ · Albert : gratuit, quotas.

Deux cas d'usage, deux logiques de coût

Sur poste : abonnement (siège) ou clé. En CI/CD : paiement au token pour tous.



Code agentique sur poste

- **Claude Code** : siège 20–125 \$/dev/mois
- **Vibe (Mistral)** : plan 14,99–24,99 \$/m ou clé API
- **OpenCode + OpenRouter** : clé, paiement au token
- **OpenCode + Albert** : clé agent État, gratuit



Bots sur CI/CD

- **Au token pour tous** : pas de siège, clé API
- **Tarifs / 1M en sortie** : de 0,87 \$ (DeepSeek) à 50 \$ (Fable 5)
- **Albert** : gratuit mais quotas 10–50 req/min

Recommandation selon la priorité



Performance

Claude Code · Fable 5

95,0 % SWE-bench, via Bedrock. *Le plus cher, CLOUD Act.*



Souveraineté & coût

Albert · DeepSeek Flash

Gratuit, SecNumCloud, ≈79 %.
Réservé agents État.



Conformité UE

Vibe · Mistral Medium 3.5

77,6 %, RGPD, éditeur FR. *Perf en retrait.*



Rapport perf / prix

DeepSeek V4 Pro · OR

80,6 % pour ~0,9 \$ / 1M. *Éditeur CN, routeur US.*

À noter : OpenCode + Albert documenté par la DINUM (guides.ia.numerique.gouv.fr) · catalogue Albert à confirmer via `/v1/models` · DeepSeek V4 = tarif preview · Kimi K3 = score annoncé éditeur, capacité OpenRouter limitée · Fable 5 sur Bedrock = data sharing à activer + rétention 30 j · tarifs OpenRouter = catalogue (caching –60/80 %).