

CLIENT · SECRÉTARIAT GÉNÉRAL DES MINISTÈRES SOCIAUX — DNUM

Souveraineté et performance des modèles et des harness

Ce que « souverain » et « conforme » veulent dire, ce que mesure le bench, et ce qui fait réellement la performance d'un agent de code.

Coding agentique · **Septembre 2026**



Souverain n'est pas synonyme de conforme

La conformité protège les données personnelles ; la souveraineté protège de l'accès d'un État tiers.



SOUVERAINETÉ · QUI PEUT EXIGER L'ACCÈS ?

Une question de juridiction

- **Critère** : le droit applicable à l'opérateur et à ses maisons mères, pas l'adresse des serveurs. Un acteur US en région UE reste soumis au droit US (lecture CNIL) : Bedrock, Vertex AI ou Azure, même à Paris.
- **Tiennent** : Albert et Outscale LLaaS (SecNumCloud 3.2) ; Scaleway et OVHcloud AI Endpoints (cloud FR, hors périmètre SecNumCloud).
- **Mistral** : éditeur français, mais La Plateforme a tourné sur Azure et Google Cloud. Souverain via Outscale ou en poids ouverts auto-hébergés.

CLOUD ACT (ÉTATS-UNIS, 2018) + FISA 702

Les fournisseurs soumis au droit US doivent remettre les données aux autorités américaines, où qu'elles soient stockées. **La localisation ne protège pas.**

Transferts UE-US (DPF, 2023) : validé en première instance le 03/09/2025, pourvoi pendant devant la CJUE (C-703/25 P).



CONFORMITÉ · LES DONNÉES SONT-ELLES TRAITÉES LÉGALEMENT ?

Une question de RGPD

- **Critère** : base légale, contrat de sous-traitance (DPA), sécurité, transferts hors UE encadrés.
- **Atteignable avec un acteur US** : Bedrock en région UE avec le DPA AWS est conforme RGPD ; même logique pour Vertex AI en région UE.
- **Insuffisante** : OpenRouter, routage par un intermédiaire US sans garanties UE.

SECNUMCLOUD 3.2 (ANSSI) référentiel du « cloud de confiance »

Qualification de sécurité + critères d'immunité aux lois extraterritoriales : **siège et capital dans l'UE, données, clés et administration en UE, personnel habilité.**

Doctrine « cloud au centre » : données sensibles sur cloud qualifié. Qualifiés : Outscale (héberge Albert), OVHcloud (IaaS), S3NS (Thales-Google) depuis 12/2025.

À retenir Bedrock, Vertex AI ou Azure : conformes, non souverains. Albert, Outscale, Scaleway, OVHcloud : les deux. OpenRouter : ni l'un ni l'autre. Le référencement UGAP (AWS et Google Cloud y figurent comme Outscale ou OVHcloud) est un canal d'achat, pas un label de souveraineté.

Performance, prix, souveraineté, conformité

Trois mesures de performance, prix / 1M tokens, souveraineté (CNIL), conformité RGPD · vérifié le 02/09/2026.

Harness · modèle fournisseur	DeepSWE v1.1 modèle seul · principal	Terminal-Bench 2.1 agentique	SWE-bench Verified baseline · saturé	Prix / 1M tokens entrée · sortie	Souveraineté au sens CNIL	Conformité RGPD / données
Claude Code · Opus 5 AWS Bedrock	74,0 % ±4	89,1 % *	96,0 % ^v 97,0 % *	5 \$ · 25 \$	● Non souveraine CLOUD Act	● Bonne région UE · DPA AWS
Claude Code · Fable 5 AWS Bedrock	70,0 % ±4	83,8 % ±1,2 · officiel	95,0 % ^v	10 \$ · 50 \$	● Non souveraine CLOUD Act	● Bonne région UE · DPA AWS
OpenCode · Kimi K3 OpenRouter	≈69 %	88,3 % ^v 80,9 % *	93,4 % *	2,55 \$ · 12,75 \$	● Non souveraine CN + routeur US	● Insuffisante sans garanties UE
Claude Code · Sonnet 5 AWS Bedrock	54 % ±4	80,4 % ^v 74,6 % officiel	85,2 % llm-stats	2 \$ · 10 \$	● Non souveraine CLOUD Act	● Bonne région UE · DPA AWS
OpenCode · DeepSeek V4 Flash 0731 Scaleway	53 % 54,4 % ^v	82,7 % ^v	non publié	0,40 € · 0,80 €	● Souveraine (UE) cloud FR · hébergé UE	● Bonne RGPD · cloud FR
OpenCode · GLM 5.2 Scaleway	44,0 %	81,0 % ^v	non publié	1,80 € · 5,50 €	● Souveraine (UE) cloud FR · hébergé UE	● Bonne RGPD · cloud FR
OpenCode · DeepSeek V4 Flash preview Albert (DINUM) · checkpoint à confirmer	7,3 % ^v	61,8 % ^v	73,7 % ^v	gratuit agents État	● Souveraine SecNumCloud · État FR	● Bonne cadre État

Sans marque = officiel · ^v auto-rapporté par l'éditeur · * mesure indépendante (vals.ai, Artificial Analysis) · llm-stats = agrégat non re-mesuré · aucun chiffre estimé : sans donnée, « non publié »

Ce que mesurent les trois benchmarks

Un score n'a de sens qu'avec sa question : le modèle seul, le couple modèle × harness, ou un repère historique.



PRINCIPAL · LE MODÈLE SEUL

DeepSWE v1.1

- **Quoi** : des tâches d'ingénierie logicielle réelles, résolues de bout en bout par l'agent.
- **Comment** : harness fixé pour tous (mini-swe-agent), leaderboard officiel Datacurve, incertitude publiée.
- **Ce que dit le score** : la capacité agentique intrinsèque du modèle, indépendante du harness.
- **Limite** : certains modèles absents du leaderboard (chiffre éditeur en repli).



AGENTIQUE · MODÈLE × HARNESS

Terminal-Bench 2.1

- **Quoi** : des tâches à mener dans un terminal (build, debug, data, admin), dans un conteneur isolé.
- **Comment** : harness libre, Terminus 2 en référence ou harness éditeur (ex. Claude Code) ; vérifié par tests.
- **Ce que dit le score** : la performance du couple modèle × harness en conditions d'usage.
- **Limite** : beaucoup de scores auto-rapportés, écarts avec les mesures indépendantes.



BASLINE · REPÈRE HISTORIQUE

SWE-bench Verified

- **Quoi** : 500 issues GitHub Python validées par des humains ; le patch est accepté s'il passe les tests.
- **Comment** : chaque éditeur choisit son harness et ses réglages ; peu de reproductions indépendantes.
- **Ce que dit le score** : un repère de continuité, saturé au-dessus de 90 % en tête de tableau.
- **Limite** : harness hétérogènes, chiffres surtout éditeurs : conservé grisé, jamais discriminant.

Règle de lecture DeepSWE classe les modèles ; Terminal-Bench montre ce que le harness ajoute ; SWE-bench Verified ne sert qu'à situer. Sans marque = officiel · v éditeur · * indépendant. Aucune case estimée : sans donnée, « non publié ».

Ce qui booste un modèle : harness, pratiques, orchestration

Le score du modèle seul est un plancher : le même modèle change de niveau selon son outillage et son pilotage.



1 · LE HARNESS

L'outillage du modèle

- **Outils** : édition de fichiers, shell, recherche dans le dépôt, connecteurs MCP.
- **Contexte** : compaction, fichiers de mémoire, sous-agents pour isoler les recherches.
- **Boucle agentique** : planifier, agir, vérifier, corriger ; permissions et garde-fous.
- **Taillé pour un modèle** : Claude Code, gourmand en contexte, vise le frontier ; OpenCode reste neutre.



2 · LES BONNES PRATIQUES

L'apport de l'équipe

- **Contexte projet** : un fichier d'instructions (CLAUDE.md, AGENTS.md) : conventions, commandes, architecture.
- **Spécifier avant de coder** : mode plan, tâches petites et vérifiables, critères d'acceptation.
- **Les tests comme oracle** : l'agent boucle sur les tests ; la revue humaine reste le dernier filtre.
- **Skills réutilisables** : procédures capitalisées, partagées entre équipes.



3 · L'ORCHESTRATION

Des agents en équipe

- **Découper les rôles** : planificateur, exécutant, vérificateur ; sous-agents en parallèle.
- **Router les modèles** : le frontier pour le difficile, l'économique et souverain pour le volume.
- **Workflows déterministes** : hooks, CI/CD, revues automatiques dans le pipeline.
- **Observabilité** : traces, coûts, taux de réussite par tâche pour arbitrer sur des faits.

CE QUE MONTRE LE BENCH

Même modèle : le score bouge selon le harness et la mesure.

Terminal-Bench 2.1, leaderboard officiel.

Conséquence pour le choix souverain : un modèle moins bien classé, bien harnaché et orchestré, peut couvrir une large part du quotidien ; le bench élargi tranchera.

Fable 5	Claude Code (xhigh)	83,8 %	Terminus 2	80,4 %	+3,4 pts
Sonnet 5	Claude Code (high)	74,6 %	annonce éditeur	80,4 %^v	écart 5,8 pts
Kimi K3	annonce éditeur	88,3 %^v	mesure vals.ai	80,9 %	écart 7,4 pts