RÉPUBLIQUE FRANÇAISE

Liberté
Égalité
Fraternité

Secrétariat général des ministères sociaux
Direction du numérique (DNUM) · Transformation IA

Souveraineté et performance des modèles et des harness

Ce que « souverain » et « conforme » veulent dire, ce que mesure le bench, et ce qui fait réellement la performance d'un agent de code.

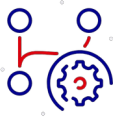
Coding agentique | 9 stacks comparées | Chiffres vérifiés le 23/09/2026 | Septembre 2026



Souveraineté
une question de juridiction, pas d'adresse



Bench
trois mesures, neuf stacks, aucun chiffre estimé



Harness
l'outillage et le pilotage font le niveau

Souverain n'est pas synonyme de conforme

La conformité protège les données personnelles ; la souveraineté protège de l'accès d'un État tiers. Deux questions, deux réponses.



SOUVERAINETÉ · QUI PEUT EXIGER L'ACCÈS ?

Une question de juridiction

- **Critère :** le droit applicable à l'opérateur et à ses maisons mères, pas l'adresse des serveurs. Un acteur US en région UE reste soumis au droit US (lecture CNIL) : Bedrock, Vertex AI ou Azure, même à Paris.
- **Tiennent :** Albert et Outscale LLMaaS (SecNumCloud 3.2) ; Scaleway et OVHcloud AI Endpoints (cloud FR, hors périmètre SecNumCloud).
- **Mistral :** éditeur français, mais La Plateforme a tourné sur Azure et Google Cloud. Souverain via Outscale ou en poids ouverts auto-hébergés.



CONFORMITÉ · LES DONNÉES SONT-ELLES TRAITÉES LÉGALEMENT ?

Une question de RGPD

- **Critère :** base légale, contrat de sous-traitance (DPA), sécurité, transferts hors UE encadrés.
- **Avec un acteur US :** Bedrock en profil UE avec le DPA AWS est conforme RGPD (Opus 5.5, Sonnet 5). Les modèles OpenAI et Fable 5.1 n'ont pas de profil UE sur Bedrock : traitement aux États-Unis, conformité sous conditions (transfert encadré : DPF, clauses types).
- **Insuffisante :** OpenRouter, routage par un intermédiaire US sans garanties UE.

CLOUD ACT (ÉTATS-UNIS, 2018) + FISA 702

Les fournisseurs soumis au droit US doivent remettre les données aux autorités américaines, où qu'elles soient stockées. **La localisation ne protège pas.**

Transferts UE-US (DPF, 2023) : validé en première instance le 03/09/2025, pourvoi pendant devant la CJUE (C-703/25 P).

SECNUMCLOUD 3.2 (ANSSI) référentiel du « cloud de confiance »

Qualification de sécurité + critères d'immunité aux lois extraterritoriales : **siège et capital dans l'UE, données, clés et administration en UE, personnel habilité.**

Doctrine « cloud au centre » : données sensibles sur cloud qualifié. Qualifiés : Outscale (héberge Albert), OVHcloud (IaaS), S3NS (Thales-Google) depuis 12/2025.

À retenir Bedrock (Claude comme GPT), Vertex AI ou Azure : conformes quand le modèle est servi en résidence UE, jamais souverains. Albert, Outscale, Scaleway, OVHcloud : les deux. OpenRouter : ni l'un ni l'autre. Le référencement UGAP est un canal d'achat, pas un label de souveraineté.

Performance, prix, souveraineté, conformité

Trois mesures de performance, prix par million de tokens (entrée · sortie), souveraineté au sens CNIL, conformité RGPD · vérifié le 23/09/2026.

Harness · modèle fournisseur	DeepSWE v1.1 modèle seul · principal	Terminal-Bench 2.1 agentique	SWE-bench Verified baseline · saturé	Prix / 1M tokens entrée · sortie	Souveraineté au sens CNIL	Conformité RGPD / données
Claude Code · Opus 5.5 AWS Bedrock	**74,2 %ᵛ** hors leaderboard	*non publié* TB 4.0 : 66,4 %ᵛ	*non publié* SWE-bench Pro 89,9ᵛ	**4 $** · 20 $	NON SOUVERAINE CLOUD Act	BONNE profil UE · DPA AWS
Codex CLI · GPT-5.6 Terra AWS Bedrock	**69,6 %** ±2,6	78,4 % ±2,5 · 87,4 %ᵛ annonce	*non publié*	**2 $** · 12 $	NON SOUVERAINE CLOUD Act	SOUS CONDITIONS traitement hors UE (États-Unis)
OpenCode · Kimi K3 OpenRouter	**69 %** ±5	88,3 %ᵛ 80,9 % *	93,4 % *	**3 $** · 15 $	NON SOUVERAINE CN + routeur US	INSUFFISANTE sans garanties UE
Codex CLI · GPT-6 Sol AWS Bedrock · GA du 22/09, fiche AWS à venir	**68,8 %ᵛ** hors leaderboard	83,2 % * vals.ai	*non publié*	**2 $** · 10 $ Bedrock : non publié	NON SOUVERAINE CLOUD Act	SOUS CONDITIONS hors UE · régions non publiées
Claude Code · Fable 5.1 AWS Bedrock	**67,4 %ᵛ** hors leaderboard	91,4 % * Terminus 2 · AA	*non publié* SWE-bench Pro 81,2ᵛ	**10 $** · 50 $	NON SOUVERAINE CLOUD Act	SOUS CONDITIONS hors UE · rétention 30 j AWS
Claude Code · Sonnet 5 AWS Bedrock	**53,8 %** ±4,2	80,4 %ᵛ 74,6 % officiel	85,2 %ᵛ 79,6 % *	**2 $** · 10 $	NON SOUVERAINE CLOUD Act	BONNE profil UE · DPA AWS
OpenCode · DeepSeek V4 Flash 0731 Scaleway	**53 %** 54,4 %ᵛ	82,7 %ᵛ	*non publié*	**0,40 €** · 0,80 €	SOUVERAINE (UE) cloud FR · hébergé UE	BONNE RGPD · cloud FR
OpenCode · DeepSeek V4 Flash 0731 Albert (DINUM) · expérimentation, contexte 131k	**53 %** ±4	82,7 %ᵛ	*non publié*	**gratuit** agents de l'État	SOUVERAINE SecNumCloud · État FR	BONNE cadre État
OpenCode · GLM 5.2 Scaleway	**44,0 %**	81,0 %ᵛ	*non publié*	**1,80 €** · 5,50 €	SOUVERAINE (UE) cloud FR · hébergé UE	BONNE RGPD · cloud FR

*Sans marque = officiel · ᵛ auto-rapporté par l'éditeur · * mesure indépendante (vals.ai, Artificial Analysis) · aucun chiffre estimé : sans donnée, « non publié » · prix publics hors remises (Bedrock : profil Global ; résidence UE en profil Geo : +10 %), Scaleway en euros HT · TB 4.0 = nouveau Terminal-Bench, non comparable au 2.1*

Ce que mesurent les trois benchmarks

Un score n'a de sens qu'avec sa question : le modèle seul, le couple modèle × harness, ou un repère historique.



PRINCIPAL · LE MODÈLE SEUL

DeepSWE v1.1

- **Quoi :** des tâches d'ingénierie logicielle réelles, résolues de bout en bout par l'agent.
- **Comment :** harness fixé pour tous (mini-swe-agent), leaderboard officiel Datacurve, incertitude publiée.
- **Ce que dit le score :** la capacité agentique intrinsèque du modèle, indépendante du harness.
- **Limite :** certains modèles absents du leaderboard (chiffre éditeur en repli, ou « non publié »).



AGENTIQUE · MODÈLE × HARNESS

Terminal-Bench 2.1

- **Quoi :** des tâches à mener dans un terminal (build, debug, data, admin), dans un conteneur isolé.
- **Comment :** harness libre, Terminus 2 en référence ou harness éditeur (Claude Code, Codex CLI) ; vérifié par tests.
- **Ce que dit le score :** la performance du couple modèle × harness en conditions d'usage.
- **Limite :** beaucoup de scores auto-rapportés, écarts avec les mesures indépendantes.



BASELINE · REPÈRE HISTORIQUE

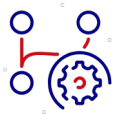
SWE-bench Verified

- **Quoi :** 500 issues GitHub Python validées par des humains ; le patch est accepté s'il passe les tests.
- **Comment :** chaque éditeur choisit son harness et ses réglages ; peu de reproductions indépendantes.
- **Ce que dit le score :** un repère de continuité, saturé au-dessus de 90 % en tête de tableau.
- **Limite :** harness hétérogènes, chiffres surtout éditeurs : conservé grisé, jamais discriminant.

Règle de lecture DeepSWE classe les modèles ; Terminal-Bench montre ce que le harness ajoute ; SWE-bench Verified ne sert qu'à situer. Sans marque = officiel · ᵛ éditeur · * indépendant. Aucune case estimée : sans donnée, « non publié ».

Ce qui booste un modèle : harness, pratiques, orchestration

Le score du modèle seul est un plancher : le même modèle change de niveau selon son outillage et son pilotage.



1 · LE HARNESS

L'outillage du modèle

- **Outils :** édition de fichiers, shell, recherche dans le dépôt, connecteurs MCP.
- **Contexte :** compaction, fichiers de mémoire, sous-agents pour isoler les recherches.
- **Boucle agentique :** planifier, agir, vérifier, corriger ; permissions et garde-fous.
- **Taillé pour un modèle :** Claude Code et Codex CLI, gourmands en contexte, visent le frontier ; OpenCode reste neutre.



2 · LES BONNES PRATIQUES

L'apport de l'équipe

- **Contexte projet :** un fichier d'instructions (CLAUDE.md, AGENTS.md) : conventions, commandes, architecture.
- **Spécifier avant de coder :** mode plan, tâches petites et vérifiables, critères d'acceptation.
- **Les tests comme oracle :** l'agent boucle sur les tests ; la revue humaine reste le dernier filtre.
- **Skills réutilisables :** procédures capitalisées, partagées entre équipes.



3 · L'ORCHESTRATION

Des agents en équipe

- **Découper les rôles :** planificateur, exécutant, vérificateur ; sous-agents en parallèle.
- **Router les modèles :** le frontier pour le difficile, l'économique et souverain pour le volume.
- **Workflows déterministes :** hooks, CI/CD, revues automatiques dans le pipeline.
- **Observabilité :** traces, coûts, taux de réussite par tâche pour arbitrer sur des faits.

CE QUE MONTRE LE BENCH

Même modèle : le score bouge selon le harness et la mesure.

Terminal-Bench 2.1 · officiel (03/09/2026) et indépendant.

GPT-5.5	Codex (xhigh)	83,2 %	Terminus 2 (xhigh)	78,0 %	+5,2 pts
Fable 5	Claude Code (xhigh)	83,8 %	Terminus 2 (high)	80,4 %	+3,4 pts
Sonnet 5	Claude Code (high)	74,6 %	annonce éditeur	80,4 %[v]	écart 5,8 pts
Kimi K3	annonce éditeur	88,3 %[v]	mesure vals.ai	80,9 %	écart 7,4 pts

Conséquence pour le choix souverain : un modèle moins bien classé, bien harnaché et orchestré, peut couvrir une large part du quotidien ; le bench élargi tranchera.